SVEUČILIŠTE U SPLITU
PRIRODOSLOVNO-MATEMATIČKI FAKULTET
Stohastičke simulacije u klasičnoj i kvantnoj fizici

Kritično ponašanje stohastičkog SIR modela na kvadratnoj rešetci

Student: Karla Belak

Split, 20.05.2026.

Sadržaj

1 Uvod **2**

2 Teorijski uvod u model i metode **2**
2.1 Stohastički SIR model 2
2.2 Efekti razrjeđivanja rešetke - imunizacija 3

3 Algoritam i računalni kod **4**
3.1 Monte Carlo SIR model 4
3.2 Implementacija razrjeđivanja rešetke 7

4 Rezultati i diskusija **9**
4.1 Veza s perkolacijom 9
4.2 MC SIR model 10
4.3 MC SIR model uz efekt razrjeđivanja 14

5 Literatura **16**

1 Uvod

Stohastička simulacija SIR (Susceptible, Infected, Recovered) modela realizirana je pomoću i temelji se na znanstvenom radu [2]. Cilj ovog seminara jest proučiti kritično ponašanje SIR modela te u njegovom ponašanju pronaći određene paralele s teorijom perkolacije analizom relevantnih veličina sustava i njihovog ponašanja u blizini procijenjene kritične točke. Također je provedena analiza za sustav koji je podvrgnut razrjeđivanju, odnosno sustav varijabilne gustoće čvorova.

2 Teorijski uvod u model i metode

2.1 Stohastički SIR model

U skladu s [2] razvijen je algoritam za numeričku simulaciju evolucije sustava te izračun relevantnih fizikalnih veličina.

Stohastički SIR model definiran je na standardnoj kvadratnoj rešetki s N čvorova, pri čemu je ukupan broj N određen linearnom veličinom rešetke L kao:

$$N = L^2. \tag{1}$$

Svaki čvor mreže predstavlja jednog pojedinca koji se može nalaziti u jednom od tri moguća stanja;

- S (susceptible) - podložan,
- I (infected) - zaražen,
- R (recovered) - oporavljen.

Unutar modela mogući su prijelazi;

$$S \to I, \tag{2}$$

te

$$I \to R. \tag{3}$$

Također, pretpostavlja se da oporavljeni pojedinac više ne može biti ponovno zaražen.

Model je moguće opisati jednim parametrom, odnosno njegovim komplementom:

- reducirana stopa infekcije b,
- reducirana stopa imunizacije c.

Vrijedi relacija:

$$b + c = 1. \tag{4}$$

U svakom vremenskom koraku slučajno se odabire jedan čvor rešetke te se vrijeme povećava za faktor $1/N$. Budući da sustav sadrži ukupno N čvorova, nakon približno N slučajnih odabira svaki je čvor u prosjeku bio odabran jednom, čime se ostvaruje jedna Monte Carlo jedinica vremena.

Stanja više čvorova ne ažuriraju se odjednom (računalna zahtjevnost), već se za odabrani čvor provodi nasumično ažuriranje stanja. Ako se čvor nalazi u stanju S, može prijeći u stanje I s vjerojatnošću proporcionalnom udjelu zaraženih susjeda prema formuli:

$$P(S \to I) = b \times \textit{(udio zaraženih susjeda)}. \tag{5}$$

Na kvadratnoj rešetki svaki čvor ima četiri najbliža susjeda pa je vjerojatnost infekcije definirana izrazom:

$$P(S \to I) = b\frac{n_I}{4}, \tag{6}$$

gdje n_I predstavlja broj zaraženih susjednih čvorova.

Nadalje, ako se odabrani čvor nalazi u stanju I, može prijeći u stanje R s vjerojatnošću:

$$P(I \to R) = c. \tag{7}$$

U svakom trenutku vrijedi:

$$N_S + N_I + N_R = N. \tag{8}$$

Monte Carlo simulacijom izračunate su i pohranjene sljedeće veličine:

- perkolacijska vjerojatnost P (tzv. order parameter),
- srednja vrijednost broja oporavljenih čvorova

$$S = \langle N_R \rangle, \tag{9}$$

- kvadrat srednje vrijednosti broja oporavljenih

$$M = \langle N_R^2 \rangle. \tag{10}$$

Posebno je zanimljivo promatrati ponašanje omjera:

$$U = \frac{M}{S^2}, \tag{11}$$

kao i umnoška UP u području kritičnosti.

Perkolacijski parametar P predstavlja vjerojatnost da epidemija formira makroskopski klaster oporavljenih koji dodiruje rub sustava. Time se uspostavlja direktna povezanost između epidemijskog prijelaza i teorije perkolacije.

Sve navedene veličine promatrane su u ovisnosti o parametru c, s posebnim naglaskom na područje kritične vrijednosti sustava određene u [2].

2.2 Efekti razrjeđivanja rešetke - imunizacija

Na osnovni model moguće je uvesti dodatne efekte i proučavati njihov utjecaj na kritično ponašanje sustava. Po uzoru na rad [3], uveden je efekt razrjeđivanja rešetke koji odgovara prisutnosti unaprijed imuniziranih pojedinaca.

Dio čvorova unaprijed se uklanja iz dinamike sustava te ne može sudjelovati u procesu širenja zaraze. Takvi čvorovi predstavljaju imunizirane pojedince koji ne mogu biti zaraženi niti širiti infekciju. Stoga u proširenom modelu svaki čvor mreže predstavlja jednog pojedinca koji se može nalaziti u jednom od četiri moguća stanja;

- S (susceptible) - podložan,
- I (infected) - zaražen,
- R (recovered) - oporavljen
- E (empty) - prazno ili blokirano (imunizirano).

Razrjeđivanje rešetke definira gustoća zauzetih čvorova pomoću koje je određena vjerojatnost da čvor bude imuniziran;

$$\rho = \frac{N}{V} \tag{12}$$

gdje je $V = L^d$, $d = 2$ za dvodimenzionalne sustave.

Smanjenjem gustoće aktivnih čvorova očekuje se smanjenje povezanosti sustava i mogućnosti formiranja makroskopskog klastera oporavljenih, što dovodi do smanjenja perkolacijske vjerojatnosti i otežava razvoj epidemije kroz cijeli sustav. Kao što [3] navodi, postoji iznos gustoće koji definira granicu između dva stanja; aktivno (zaraza se može širiti) i neaktivno (apsorbirajuća, faza bez širenja) neovisno o stopi infekcije/imunizacije.

3 Algoritam i računalni kod

3.1 Monte Carlo SIR model

Računalni algoritam koncipiran je stvaranjem kvadratne rešetke dimenzije L s ukupno N čvorova, pri čemu vrijedi:

$$N = L^2. \tag{13}$$

S obzirom da je cilj promatrati ponašanje epidemije za različite veličine sustava i različite vrijednosti parametra c, prvi korak implementacije bio je definiranje parametara simulacije. Operacije su provedene nad rešetkama veličina:

$$L = 32,\ 64,\ 128. \tag{14}$$

Vrijednosti parametra c uzete su u području oko poznate kritične c_c:

$$c_c \approx 0.1765 \tag{15}$$

prema radu [2]. Također je definiran broj realizacija simulacije n za svaki skup parametara, budući da je zbog statističke prirode Monte Carlo metode potrebno provesti više neovisnih simulacija i računati veličine usrednjene po svim realizacijama tj. ansamblu. U simulacijama je korišteno:

$$n = 1000 \tag{16}$$

realizacija po točki.

U svrhu pohrane i praćenja stanja svih čvorova tijekom evolucije sustava svakom je stanju pridružen numerički zapis:

- 0 - susceptible,
- 1 - infected,
- 2 - recovered.

Tako je moguće jednostavno spremanje podataka u matricu koja predstavlja rešetku sustava. Nakon definiranja osnovnih parametara konstruirane su funkcije koje predstavljaju gradivne blokove stohastičkog SIR modela.

Na slici 1 prikazana je funkcija koja provjerava broj zaraženih susjednih čvorova za odabrani položaj (x, y) na rešetci. S obzirom da se radi o dvodimenzionalnoj kvadratnoj rešetki, provjeravaju se četiri najbliža susjeda; gore, dolje, lijevo i desno.

U funkciji se koriste periodični rubni uvjeti implementirani kao:

$$(x - 1 + L)\%L, \tag{17}$$

```python
#Stanjima pripisane vrijednosti da bi mogli mapirat/spremit
SUSCEPTIBLE = 0
INFECTED = 1
RECOVERED = 2

#Fja provjera kroz petlju koliko je inficiranih susjeda (bitno za vjerojatnost inficiranja)
@njit
def infected_neighbors(lattice, x, y, L):

    count = 0

    #Gore
    if lattice[(x - 1 + L) % L, y] == INFECTED:
        count += 1

    #Dolje
    if lattice[(x + 1) % L, y] == INFECTED:
        count += 1

    #Lijevo
    if lattice[x, (y - 1 + L) % L] == INFECTED:
        count += 1

    #Desno
    if lattice[x, (y + 1) % L] == INFECTED:
        count += 1

    return count
```

Figure 1: Funkcija provjere zaraženih susjeda

```python
#Fja jedna realizacija MC simulacije epidemije
@njit
def run_sir(L, c):

    b = 1.0 - c

    lattice = np.zeros((L, L), dtype=np.int8)

    center = L // 2

    lattice[center, center] = INFECTED

    touched_boundary = 0

    N = L*L

    infected_exists = True

    while infected_exists:

        infected_exists = False

        #Jedan Monte Carlo sweep
        for _ in range(N):

            #Slučajni čvor
            x = np.random.randint(L)
            y = np.random.randint(L)

            state = lattice[x, y]

            #Zaraza
            if state == SUSCEPTIBLE:

                n_inf = infected_neighbors(lattice, x, y, L)

                infection_probability = b * (n_inf / 4.0) #Vjerojatnost ovisi o udjelu zaraženih susjeda (od 4)

                if np.random.random() < infection_probability:

                    lattice[x, y] = INFECTED

                    if x == 0 or y == 0 or x == L-1 or y == L-1:
                        touched_boundary = 1
```

Figure 2: Početak funkcije *run_sir*

```
87              #Oporavak
88              elif state == INFECTED:
89
90                  infected_exists = True
91
92                  if np.random.random() < c:
93
94                      lattice[x, y] = RECOVERED
95
96      recovered = np.sum(lattice == RECOVERED)
97
98      return recovered, touched_boundary
```

Figure 3: Monte Carlo dinamika funkcije *run_ sir*

čime su lijevi i desni rub sustava međusobno povezani, kao i gornji i donji. Tako se smanjuje utjecaj rubnih efekata i sustav bolje aproksimira beskonačnu rešetku.

Na slikama 2 i 3 prikazana je funkcija *run_ sir* koja predstavlja jednu realizaciju epidemije za zadani skup parametara (L, c).

Unutar funkcije prvo se izračunava parametar:

$$b = 1 - c, \tag{18}$$

zatim se inicijalizira rešetka i postavlja početni zaraženi čvor u središte sustava koji služi kao okidač dinamike epidemije.

Glavna Monte Carlo petlja implementirana je pomoću *while* petlje koja osigurava izvođenje simulacije dok god u sustavu postoji barem jedan zaraženi čvor. Kada više nema čvorova u stanju I, epidemija završava i simulacija se prekida.

Unutar glavne petlje izvodi se jedan Monte Carlo prolaz tijekom kojeg se približno N puta nasumično odabire čvor rešetke. Time se osigurava da svaki čvor u prosjeku bude odabran jednom tijekom jedne jedinice vremena.

Pomoću *NumPy random* generatora bira se slučajan čvor te se provjerava njegovo stanje. Ako se čvor nalazi u stanju S, poziva se funkcija sa slike 1 kojom se određuje broj zaraženih susjeda. Na temelju toga računa se lokalna vjerojatnost infekcije:

$$P(S \to I) = b\frac{n_I}{4}, \tag{19}$$

gdje n_I predstavlja broj zaraženih susjeda.

Generiranjem novog slučajnog broja određuje se hoće li čvor prijeći u stanje I. Tijekom simulacije također se provjerava dodiruje li klaster oporavljenih rub sustava, što je potrebno za određivanje perkolacijske vjerojatnosti P.

Ako se odabrani čvor nalazi u stanju I, može prijeći u stanje R s vjerojatnošću:

$$P(I \to R) = c. \tag{20}$$

Na kraju svake realizacije određuje se ukupan broj oporavljenih čvorova. Upravo oporavljeni klaster predstavlja analogon klasteru iz teorije perkolacije.

Na slici 4 prikazan je dio koda u kojem se za svaki skup parametara (L, c) provodi Monte Carlo simulacija pozivanjem prethodno definiranih funkcija. Dobivene vrijednosti relevantnih veličina pohranjuju se u polja i matrice radi kasnije analize i crtanja grafova.

```python
#Monte Carlo
results = []

for L in L_values:

    print(f"Simuliranje L = {L}")

    avg_sizes = np.zeros(len(c_values))
    second_moments = np.zeros(len(c_values))
    binder_ratios = np.zeros(len(c_values))
    percolation_probs = np.zeros(len(c_values))

    for ic, c in enumerate(c_values):

        cluster_sizes = np.zeros(n_simulations)

        percolating = 0

        for sim in range(n_simulations):

            #Runnanje funkcije
            size, touched = run_sir(L, c)

            cluster_sizes[sim] = size
            #Parametar touched opisuje u koliko iteracija je dotaknuta stranica kod klastera (nastao tzv beskonačni klaster)
            percolating += touched

        #Relevantne veličine za evaluaciju modela...
        S = np.mean(cluster_sizes)

        M = np.mean(cluster_sizes**2)

        U = M / (S**2)

        #Order parametar definiran da odgovara perkolacijskom usporedbe radi
        P = percolating / n_simulations

        #Specifičan c
        avg_sizes[ic] = S
        second_moments[ic] = M
        binder_ratios[ic] = U
        percolation_probs[ic] = P
```

Figure 4: Monte Carlo simulacija za skup parametara (L, c)

Potrebno je napomenuti da je simulacija računalno zahtjevna zbog velikog broja petlji, slučajnih ažuriranja i operacija nad matricama. "Obični" *Python* kod pokazao se relativno sporim za izvođenje velikog broja Monte Carlo realizacija, osobito za veće sustave. Zbog toga je korišten paket *Numba*, odnosno JIT (*Just-In-Time*) kompajler za *Python*. Uloga *Numbe* je prevođenje *Python* funkcija u optimizirani strojni kod tijekom izvođenja programa.

Na prethodnim slikama može se primijetiti oznaka *@njit* prije definicije funkcija. Prilikom prvog izvođenja funkcije *Numba* analizira tipove podataka, kompajlira funkciju u niskorazinski kod te izvršava optimiziranu verziju funkcije. Time se značajno ubrzava izvođenje Monte Carlo simulacije, osobito kod velikog broja iteracija i operacija unutar petlji [4].

3.2 Implementacija razrjeđivanja rešetke

Na osnovni SIR model uveden je efekt razrjeđivanja rešetke kojim se simulira prisutnost početno imuniziranih pojedinaca. U numeričkoj implementaciji dio čvorova unaprijed se uklanja iz dinamike sustava te im se pridružuje posebno stanje koje ne može sudjelovati u procesu širenja zaraze. Moguća stanja i pripadne vrijednosti za izmijenjeni model:

- 0 - susceptible,
- 1 - infected,
- 2 - recovered,
- -1 - empty.

Razrjeđivanje je definirano parametrom gustoće:

$$\rho, \tag{21}$$

koji predstavlja udio aktivnih čvorova u sustavu. Svaki čvor rešetke inicijalno se postavlja kao aktivan s vjerojatnošću ρ, dok je

$$1 - \rho \tag{22}$$

vjerojatnost da je uklonjen iz dinamike sustava. Na slici 5 prikazana je funkcija koja stohastički na navedeni način modificira kvadratnu rešetku i dodaje efekt razrjeđivanja.

```
38  @njit
39  def initialize_lattice(L, rho):
40
41      lattice = np.zeros((L, L), dtype=np.int8)
42
43      for x in range(L):
44          for y in range(L):
45
46              #Site nije blokiran
47              if np.random.random() > rho:
48                  lattice[x, y] = EMPTY
49
50              else:
51                  lattice[x, y] = SUSCEPTIBLE
52
53      return lattice
```

Figure 5: Funkcija koja modificira kvadratnu mrežu ovisno o gustoći čvorova.

Na taj način smanjuje se povezanost rešetke i broj mogućih puteva širenja zaraze. Tijekom simulacije infekcija se može širiti isključivo preko aktivnih čvorova, dok imunizirani čvorovi ne mogu prijeći ni u jedno stanje SIR dinamike.

Monte Carlo simulacija provodi se slično osnovnom modelu uz dodatak provjere stanja prikazan na slici 6.

Promatra se utjecaj razrjeđivanja na:

- prosječnu veličinu epidemije,
- perkolacijsku vjerojatnost,
- kritično ponašanje sustava.

```python
@njit
def run_sir_diluted(L, c, rho):

    b = 1.0 - c

    lattice = initialize_lattice(L, rho)

    center = L // 2

    #Sada je potrebno osigurati da radimo na aktivnom čvoru
    while lattice[center, center] == EMPTY:

        center += 1

        if center >= L:
            center = L // 2
            break

    lattice[center, center] = INFECTED
```

Figure 6: Funkcija koja osigurava početak širenja postavljanjem prvog zaraženog u ne-blokirano mjesto.

4 Rezultati i diskusija

4.1 Veza s perkolacijom

Temeljna ideja rada [2] jest provjeriti tvrdnju da klasteri oporavljenih čvorova generirani stohastičkim SIR modelom slijede statistiku raspodjele veličina klastera iz standardne teorije perkolacije.

U tom slučaju klaster oporavljenih formiran tijekom epidemije odgovara perkolacijskom klasteru, dok srednja veličina klastera u teoriji perkolacije odgovara srednjem broju oporavljenih čvorova u SIR modelu.

U radu su analizirane veličine dobivene Monte Carlo simulacijom:

- perkolacijska vjerojatnost P,
- srednja vrijednost broja oporavljenih S,
- kvadrat srednje vrijednosti broja oporavljenih M,
- omjer

$$U = \frac{M}{S^2}. \tag{23}$$

Navedene veličine promatraju se kao funkcije parametra c, pri čemu je cilj analizirati njihovo ponašanje u području predviđene kritične točke.

Kao i u teoriji perkolacije, očekuje se postojanje kritične vrijednosti parametra:

$$c_c, \tag{24}$$

za koju vrijedi:

- $c < c_c$ - epidemija se može proširiti kroz cijeli sustav i formirati makroskopski odnosno perkolirajući klaster,

- $c > c_c$ - pojavljuju se mali klasteri i lokalizirane epidemije,
- $c = c_c$ - javljaju se velike fluktuacije karakteristične za kritično ponašanje i fazni prijelaz.

Ako dobiveni grafovi pokazuju navedena ponašanja, moguće je zaključiti da se epidemijski prijelaz u stohastičkom SIR modelu može interpretirati kao perkolacijski fazni prijelaz [1].

4.2 MC SIR model

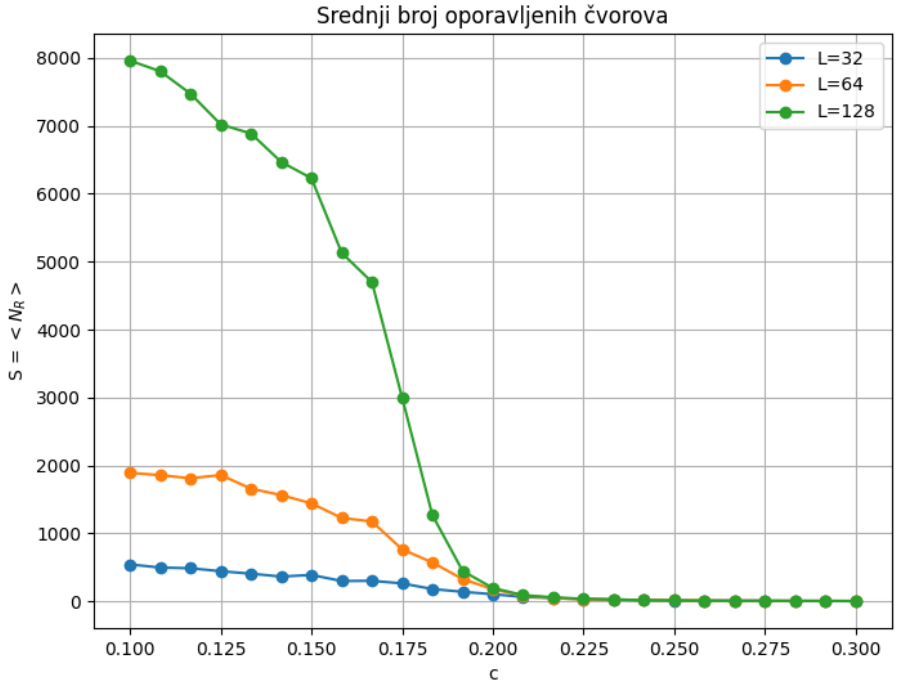


Figure 7: Prosječan broj oporavljenih čvorova S u ovisnosti o parametru c

Na grafu 7 prikazana je srednja vrijednost broja oporavljenih čvorova:

$$S = \langle N_R \rangle \tag{25}$$

u ovisnosti o parametru c. Za male vrijednosti parametra c broj oporavljenih čvorova je velik, što znači da se epidemija uspješno širi kroz sustav i zahvaća značajan dio populacije. U tom području vrijednost parametra infekcije:

$$b = 1 - c \tag{26}$$

je velika, pa je prijenos zaraze dominantan u odnosu na proces oporavka.

Povećanjem parametra c dolazi do naglog smanjenja veličine klastera oporavljenih. Time epidemija postupno prelazi iz makroskopskog režima, u kojem se zaraza širi kroz velik dio sustava, u lokalizirani u kojem se epidemija brzo gasi i stoga zahvaća samo mali broj čvorova.

Može se uočiti najizraženija promjena događa u području:

$$c \approx 0.18, \tag{27}$$

što predstavlja inicijalnu procjenu kritične vrijednosti:

$$c_c. \tag{28}$$

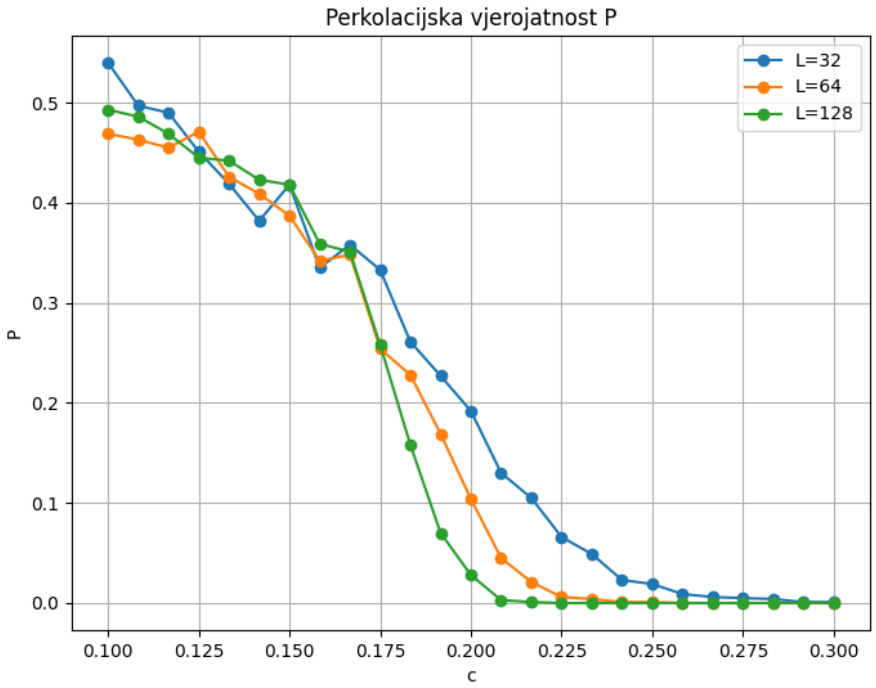


Figure 8: Perkolacijska vjerojatnost P u ovisnosti o parametru c

Na grafu 8 prikazana je perkolacijski parametar P, odnosno vjerojatnost da klaster oporavljenih dosegne rub sustava i formira makroskopski klaster. Za male vrijednosti parametra c vrijednost P je velika, što znači da epidemija često uspijeva propagirati kroz cijeli sustav.

Povećanjem parametra c perkolacijski parametar naglo opada, s obzirom da se povećava vjerojatnost oporavka zaraženih čvorova prije nego što uspiju prenijeti zarazu na veći broj susjeda. Za:

$$c > c_c \tag{29}$$

vrijednost P teži prema nuli, što odgovara lokaliziranim epidemijama koje ne uspijevaju formirati perkolirajući klaster.

Najveća promjena u ponašanju perkolacijske vjerojatnosti ponovno se pojavljuje u području:

$$c_c \approx 0.18, \tag{30}$$

što je u skladu s rezultatima iz rada [2]. Takvo ponašanje predstavlja karakteristično obilježje perkolacijskog faznog prijelaza.

Na grafu 9 prikazan je omjer:

$$U = \frac{M}{S^2}, \tag{31}$$

koji služi kao dodatna veličina za identifikaciju kritičnog ponašanja sustava.

U području kritične vrijednosti parametra c dolazi do pojačanih fluktuacija veličine klastera oporavljenih, što se očituje karakterističnim ponašanjem omjera U. Za različite veličine sustava krivulje pokazuju promjenu ponašanja upravo u području:

$$c \approx 0.18. \tag{32}$$

Takvo ponašanje omjera povezano je s pojavom kritičnih fluktuacija i prijelazom između faze velikih perkolirajućih klastera i faze lokaliziranih epidemija.

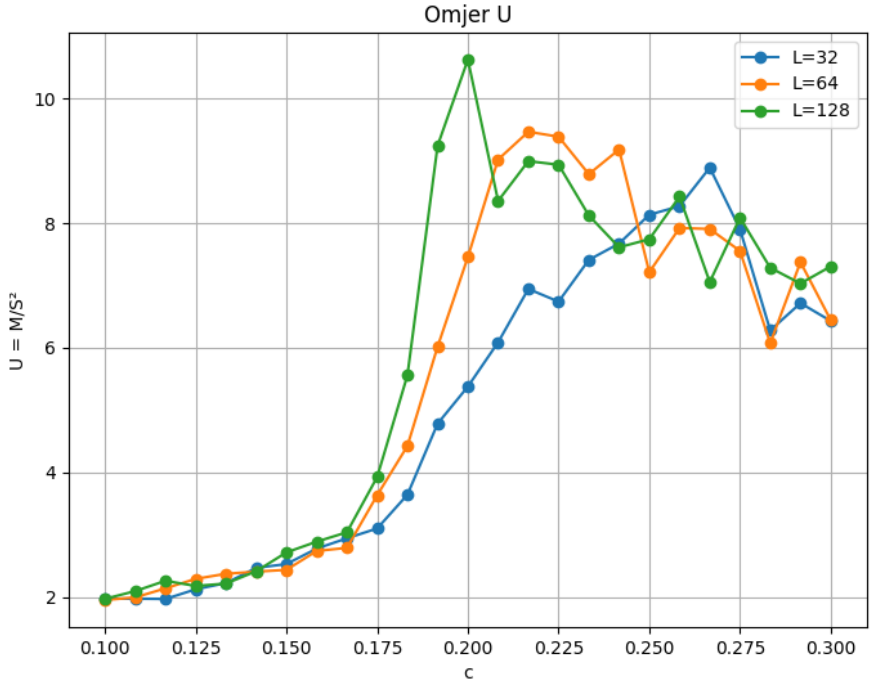


Figure 9: Omjer $U = M/S^2$ u ovisnosti o parametru c

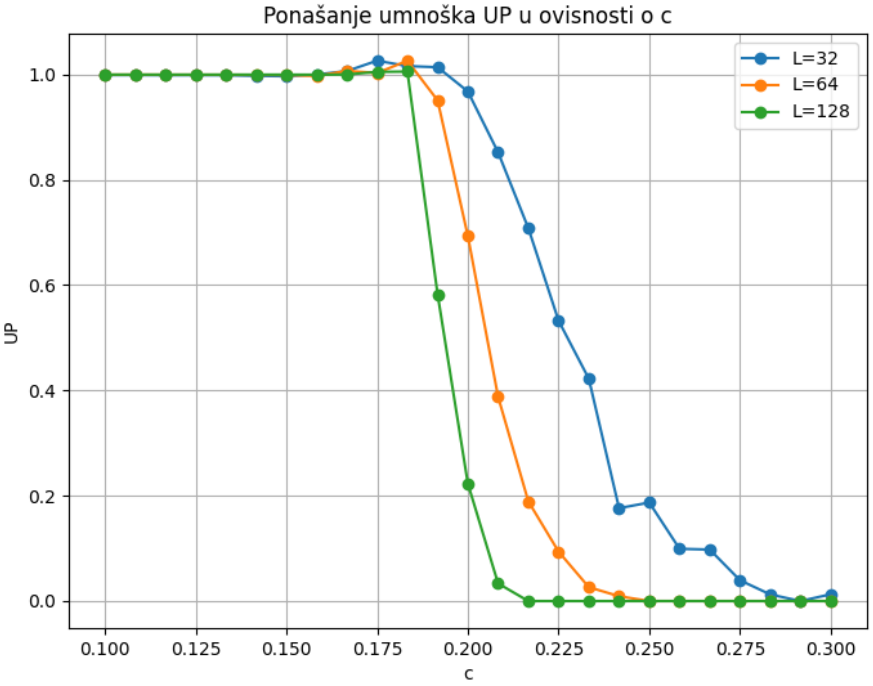


Figure 10: Umnožak $U = M/S^2$ i parametra P u ovisnosti o parametru c

Moguće je dodatno proučiti ponašanje umnoška veličina U i P kao kombiniranog indikatora u nadi za uočavanjem "čišće" slike faznog prijelaza. Kao što se može vidjeti na slici 10 istina jest da je dobiveni signal puno jasnije definira za koju vrijednost c dolazi do naglog skoka ili promjene. Ovu činjenicu možemo pripisati prirodi veličina U i P, jer njihov umnožak povezuje

globalnu epidemijsku aktivnost (P) s kritičnom strukturom klastera (U). Također, kao što je navedeno u radu [2], može opaziti da se krivulje funkcije sijeku (za dovoljno velik L) u točci koju identificiramo kao c_c.

Na temelju svih promatranih veličina moguće je procijeniti kritičnu vrijednost parametra:

$$c_c \approx 0.18. \tag{33}$$

Procjena je izvedena analizom:

- naglog pada srednje veličine recovered klastera S,
- prijelaza perkolacijske vjerojatnosti P,
- promjene ponašanja omjera U,
- te ponašanja umnoška UP.

Iako u radu nije provedena detaljna *finite-size scaling* analiza niti određivanje kritičnih eksponenata, dobiveni rezultati kvalitativno potvrđuju povezanost stohastičkog SIR modela i teorije perkolacije.

4.3 MC SIR model uz efekt razrjeđivanja

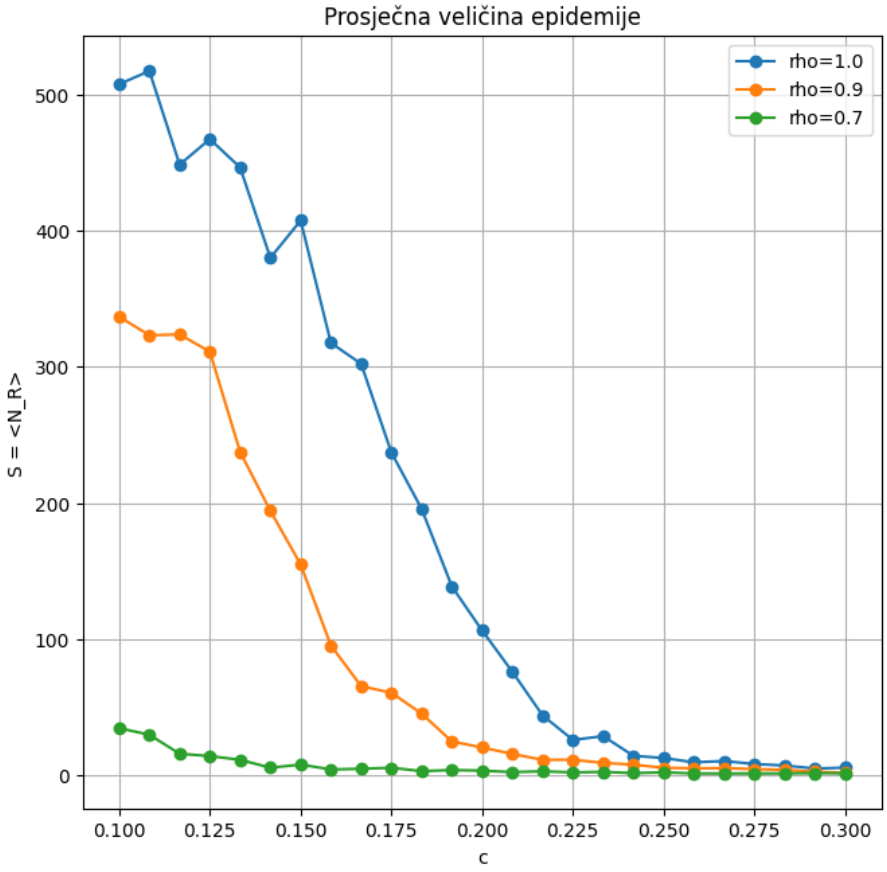


Figure 11: Prosječan broj oporavljenih čvorova S u ovisnosti o parametru c na razrijeđenoj rešetci za više vrijednosti gustoće.

Na slikama 11 i 12 prikazana je prosječna veličina epidemije u ovisnosti o c, odnosno perkolacijska vjerojatnost P za tri različite vrijednosti gustoće:

$$\rho = 0.7,\ 0.9,\ 1.0 \tag{34}$$

te za broj inicijalizacija simulacije $n = 300$.

Prvo što možemo primijetiti na slici 11 je da razrjeđivanjem krivulje ranije opadaju i imaju manju amplitudu. Ovo se može pripisati činjenici da klaster postaje manji, epidemija se teže širi te je vidljiv "slabiji" kritičan prijelaz. Sažeto, pojava imuniziranih čvorova prekida puteve širenja zaraze.

Na slici 12 može se uočiti da za manje vrijednosti gustoće, vrijednost P opada. Prijelaz se pomiče te je sveukupno teže sustavu ostvariti makroskopsku epidemiju.

Omjer U (na slici 13) za manje vrijednosti gustoće gubi tip ponašanja koji mu je tipičan u pojasu oko kritične vrijednosti c_c, a koji ukazuje na pojavu faznog prijelaza. Krivulja je većinski duž cijelog intervala konzistentno nepravilno oscilirajuća te nema vidljiv skok, što je u kontrastu s ponašanjem za veće vrijednosti gustoće.

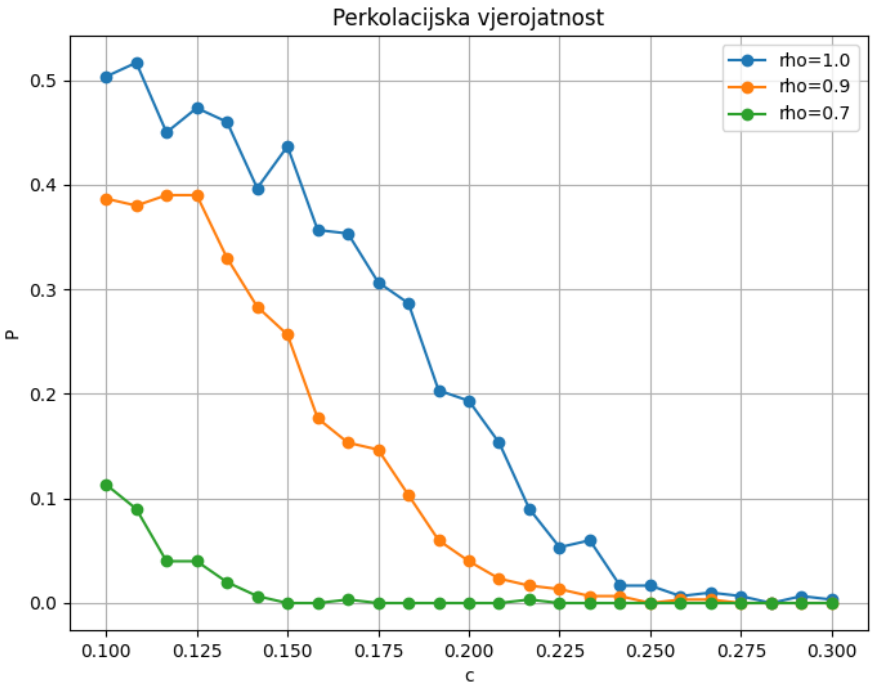


Figure 12: Perkolacijska vjerojatnost P u ovisnosti o parametru c na razrijeđenoj rešetci za više vrijednosti gustoće.

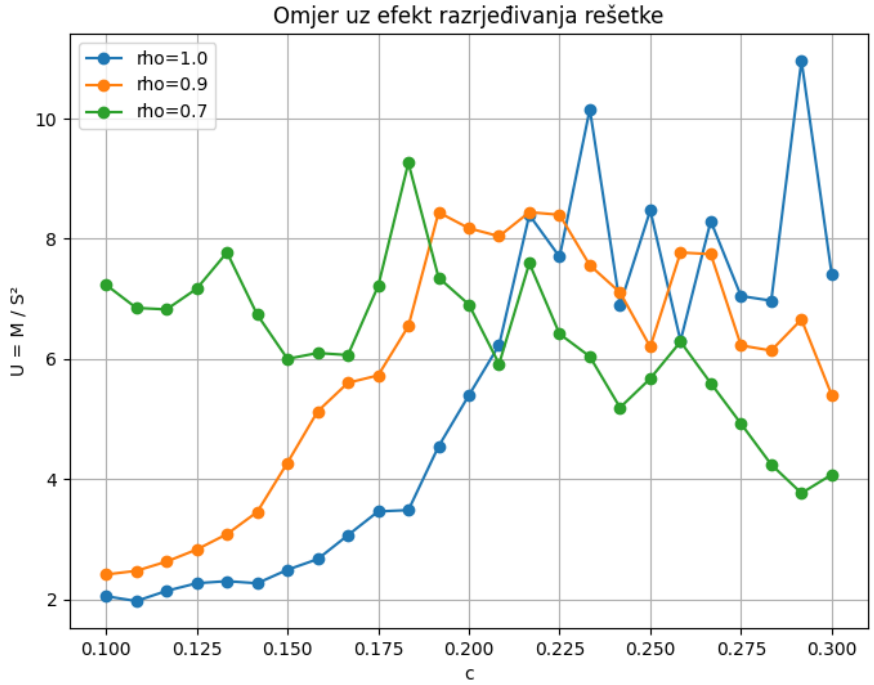


Figure 13: Omjer $U = M/S^2$ u ovisnosti o parametru c na razrijeđenoj rešetci za više vrijednosti gustoće.

5 Literatura

[1] "Stohastičke simulacije u klasičnoj i kvantnoj fizici", L. Vranješ Markić i P. Stipanović, interna skripta

[2] "A new scale-invariant ratio and finite-size scaling for the stochastic susceptible–infected–recovered model", David R de Souza, Tania Tome i Robert M Ziff

[3] "Effects of lattice dilution on the nonequilibrium phase transition in the stochastic susceptible-infectious-recovered model", Ruslan I. Mukhamadiarov, and Uwe C. Täuber

[4] `https://numba.pydata.org/`